AIDER LoRA 与 CLIP Adapter 工作记录

研究进展与实验结果　2026 年 10 月 28 日

目前完成了两项相互关联的工作：AIDER-LoRA 使用共享 Transformer 与任务专属低秩更新完成多维视频评价；CLIP 意图 Adapter 使用评估准则文本学习更符合评价意图的表示。前者已获得视频评分结果，后者已在文本意图关系和类别检索上获得改善。两者组合后的下游增益尚需单独验证。

一 AIDER LoRA 当前效果

本次结果对应两阶段 5+5 训练的 best 检查点，实验身份已确认。四个任务分别在 115 个视频上评价，共 460 条视频与任务评分记录。表中指标保留四位小数，原始数值用于宏平均核对。[S1]

任务	样本	PLCC ↑	SROCC ↑	KROCC ↑	RMSE ↓
静态质量 static	115	0.9220	0.9183	0.7512	0.0487
时序质量 temporal	115	0.9470	0.9392	0.7770	0.0483
动态程度 dynamic	115	0.6635	0.6892	0.5046	0.0699
文本视频一致性 text_video	115	0.7699	0.7454	0.5696	0.0704
宏平均	**-**	**0.8256**	**0.8230**	**0.6506**	**0.0593**

宏平均 PLCC 为 0.8256，SROCC 为 0.8230。static 与 temporal 的排序相关性较高，SROCC 分别为 0.9183 与 0.9392；dynamic 与 text_video 仍有改善空间，分别为 0.6892 与 0.7454。

PLCC 衡量线性相关性；SROCC 衡量秩相关性，也常记为 SRCC；KROCC 衡量排序一致性；RMSE 衡量当前标签尺度下的预测误差。宏指标为四个任务指标的算术平均，其中宏 RMSE 不是合并所有误差后重新计算的 RMSE。

目前的性能观察

研究者观察到 LoRA 组相较 MoE 的综合能力提升，Text-Video 的改善尤其明显，并已接近 AIGV-Assessor，部分维度超过。当前绝对分数见上表；模型间的提升幅度和持平结论，需要结合相同划分、相同选模规则下的逐维对照结果解释。

CLIP 意图 Adapter 的结果概览

在 criterion7-intent-projection-v1 的文本评估中，一级类别宏召回率为 82.16% ± 0.98%，二级维度宏召回率为 72.57% ± 3.05%，均高于原始 CLIP。细分意图排序存在取舍，完整对照见第四节。这些数值属于文本表示评估，不是视频质量预测指标。[S5]

二 AIDER LoRA 做了什么

保留原 AIDER 的三路视频证据、伪影先验和跨分支 FiLM，将融合层中的完整 FFN 专家池替换为普通共享 Transformer，并在 Attention 与 FFN 的线性投影中加入任务专属 LoRA。[S2]

部分	原 AIDER MoE 参考实现	AIDER LoRA
视频证据	VITAL 技术特征、SlowFast 运动特征、BLIP 文本视频特征	保留三路及其特征维度
技术质量	高频结构伪影先验辅助 Artifact Query	保留先验与技术特征提取方法
特征调制	任务私有 FiLM 与 alpha，其他两路视频特征提供动态残差	保留；采用 video_only 条件
时序融合	2 层，宽度 1536，12 个注意力头	相同；输入仍为 8 个时间 token
Attention	Q K V 与输出投影的参数共享	四个投影均加入任务专属 LoRA
FFN	每层 7 个路由专家选 2 个，另加 1 个常开共享专家	每层 1 个共享 FFN，fc1 与 fc2 均加入任务专属 LoRA
任务分流	任务向量决定专家与混合权重	显式任务 ID 选择对应 LoRA；回归头仍为任务私有

任务专属低秩更新

$$W_t = W_{shared} + \frac{16}{8} B_t A_t$$

每个任务在每层拥有 Q、K、V、输出投影、fc1、fc2 六处独立低秩更新。rank 为 8，alpha 为 16，LoRA dropout 为 0.05；A 独立随机初始化，B 初始化为零。初始更新为零，推理时可写为上式。混合批次只执行出现任务的 Adapter。

融合模块的参数规模

参数范围	参数量
原 MoE 融合模块 含四任务私有 Gate	94,534,712
LoRA 版共享 Transformer 基础参数	28,345,344

参数范围	参数量
四任务全部 LoRA 每任务 294,912	1,179,648
LoRA 融合模块合计	**29,524,992**

按当前源码静态计算，融合参数量下降约 68.8%。此口径排除三路编码器、FiLM 和回归头；原 MoE 采用当前根目录的私有 Gate 实现。该比例不代表整模型参数或峰值显存的降幅。

5 加 5 两阶段训练

第 1 至 5 轮训练共享 Transformer，旁路并冻结 LoRA；第 6 至 10 轮冻结融合基础线性层、偏置与 LayerNorm，启用任务 LoRA。FiLM、alpha、私有 Head、BLIP 文本与交叉注意力及其他原可训练模块继续训练。切换使用第 5 轮 last，保留其他模块 Adam 状态与全局学习率进度。[S3]

三 CLIP 意图 Adapter 做了什么

该工作针对评价描述的表示问题：相近的视觉语义和共同措辞可能使不同评价意图在原始 CLIP 空间中距离较近。通过专门构建的准则文本与关系监督，训练 CLIP 后的投影，使表示更符合评价意图的同义、差异与层级关系。此处记录 criterion7-intent-projection-v1，其他历史 Adapter 版本不混用结果。[S4]

评估意图描述数据集

criterion7_intent_v1 采用四个一级类别和七个二级维度，每个二级维度 768 条英文描述，总计 5,376 条。描述由 56 个具体意图、448 条措辞和 36 个模板构成，因而描述条数不能视为独立意图数量。[S4]

一级类别	二级评价维度
质量评价 Q	空间质量 SQ；动态质量 DQ；美学质量 AQ
真实感 R	物理常识 PC；解剖合理性 AN
内容丰富度 C	动态程度 DD
文本视频对齐 A	文本对齐 TA

划分	描述数量	具体意图数量	每个二级维度
训练集	4,032	42	576 条
验证集	672	7	96 条
测试集	672	7	96 条

划分同时留出具体准则与模板族。正样本严格保留同一个具体评估意图并改变措辞；负样本改变二级维度，同一级类别内为较弱负例，跨一级类别为较强负例。同二级类别但具体准则不同的描述不直接作为正样本或负样本。

模型与训练目标

冻结 CLIP ViT-B/32 文本编码器，输入 512 维单位化文本特征；接 Linear 512 到 512、ReLU、Linear 512 到 512，再作 L2 归一化。只训练投影层，共 525,312 个参数，没有分类头和可训练 Root 查表。[S4]

损失同时优化四项关系：同意图正样本对齐、同一级类别内的区分、跨一级类别的区分，以及同级负例应比跨级负例更接近的层级排序。相应权重依次为 0.20、0.50、1.25、0.50；同级、跨级和层级 margin 分别为 0.10、0.35、0.15。

训练协议

使用 seed 42、43、44，AdamW 学习率 0.00001、weight decay 0.01，训练 1,000 个全批次更新步，梯度范数裁剪为 1。每个训练锚点有 2 个正例、6 个负例；按一级类别及其子类别平衡锚点贡献。每 10 步评价验证损失，选择最小验证复合损失的检查点；所有检查点固定后再评估测试集。[S4]

四 CLIP 意图 Adapter 的效果

以下结果来自同一套新测试关系。意图投影与此前层级投影均报告 seed 42、43、44 的均值与样本标准差；原始 CLIP 为固定编码器结果。此前层级投影指 criterion7-hierarchy-projection-v4 的 gentle 配置。[S5]

指标	原始 CLIP	此前层级投影	意图投影
一级类别宏召回率	71.27%	76.36 ± 1.30%	82.16 ± 0.98%
二级维度宏召回率	67.11%	58.38 ± 1.21%	72.57 ± 3.05%
同意图正样本 > 跨一级负样本	24.23%	72.85 ± 1.64%	79.63 ± 0.65%
同意图正样本 > 同一级负样本	22.35%	61.34 ± 2.07%	56.45 ± 0.85%
同一级负样本 > 跨一级负样本	49.57%	64.45 ± 1.19%	78.77 ± 0.69%
完整层级顺序 p > s > c	5.61%	32.74 ± 2.85%	40.84 ± 1.06%

p 表示保留具体意图的正样本，s 表示同一级类别内其他二级维度的负样本，c 表示跨一级类别负样本；关系是否成立由余弦相似度比较。类别召回率来自训练集类中心检索诊断，未训练分类头。 “±”为三个种子的样本标准差，不是置信区间。

已观察到的改善

相较原始 CLIP，一级类别宏召回率提高 10.89 个百分点，二级维度宏召回率提高 5.46 个百分点。正样本优于跨一级负例的比例从 24.23% 提高到 79.63%，说明投影更符合当前意图关系定义。

相较此前层级投影，一级与二级宏召回率分别提高 5.80 和 14.19 个百分点；同级负例优于跨级负例的比例提高约 14.33 个百分点，完整层级排序提高约 8.11 个百分点。差值按原始结果计算，四舍五入后可能与表内百分数直接相减略有差异。

仍然存在的取舍

同意图正样本优于同一级负例的比例，从此前版本的 61.34% 降到 56.45%，下降 4.89 个百分点。因此，当前投影改善了跨大类区分和层级结构，但细粒度意图区分没有同步全面改善。

数据为合成准则和模板组合；验证集与测试集各只有 7 个独立具体意图，每个二级维度一个。672 条测试句子不能等同于 672 个独立评价意图。现有结果支持在该意图体系上的文本表示改善，对自然表述、跨数据集准则及视频 MOS 的作用需分别评价。

意图投影版本同时改变了描述覆盖与关系构造，相较此前版本的差异不能全部归因于某一个损失项。Rubric、反事实场景、宽泛名称和边界案例保留作辅助诊断，没有额外作为本轮损失输入。[S4]

五 两项工作的关系与当前判断

AIDER-LoRA 的任务能力目前主要由任务 ID 和私有参数承担。LoRA 按 ID 选择，不读取 CLIP 向量；FiLM 的任务基础线性层与 alpha 也为任务私有。当前 video_only 动态残差读取其他分支的视频摘要，不把任务向量作为其输入。[S2]

意图向量在私有 FiLM 中的作用

$$[\gamma_t, \beta_t] = W_t e_t + b_t = c_t$$

每个固定任务只有一个固定描述向量，因此该任务的基础调制输出可以直接表示为可学习常量。即使所有任务输入同一个向量，各自独立的线性层仍能学到不同的调制。alpha 同样可以表示为每任务一个可学习标量经 sigmoid 后的值。

这说明意图 Adapter 对当前四任务模型在表达能力上并非必需。它可能改变训练优化、参数正则化与归纳偏置，实际收益仍需视频评价消融证明。文本向量之间的余弦距离变大，本身不能保证下游预测提高。

更适合意图表示的使用方式

若需要自然语言选择已有评价维度，意图模块可以先将用户描述映射为任务 ID，再调用对应 LoRA。若需要意图表示直接影响融合，则可由共享 FiLM 生成器、共享 Query 生成器，或共享超网络根据意图生成适配参数。此时需要检验同义改写、细则变化和留出任务上的行为。上述连接方式属于后续设计，尚未包含在本次结果中。

优先完成的对照

对照	需要回答的问题
固定同一向量 随机向量 原始 CLIP 意图投影	统一维度和范数，检验文本意图几何是否改善当前私有模块的结果
普通共享 Transformer 与加入任务 LoRA	区分移除专家池和增加低秩任务适配各自的收益
仅 FFN LoRA 与 Attention 加 FFN LoRA	检验 Text-Video 是否主要受益于 Attention 投影适配
joint 与两阶段 5 加 5	区分共享基础参数持续训练和分阶段冻结的影响

当前意图投影基于 ViT-B/32 的 512 维特征；AIDER-LoRA 的固定任务表来自 ViT-L/14 的 768 维投影。接入实验应匹配底层编码器和维度，避免将更换 CLIP 的影响归入 Adapter。

另一个可检验的简化是直接学习任务基础 gamma、beta 与 alpha。按当前四任务三分支配置，这部分参数可由 9,452,548 减少至 12,292，不含共享视频动态调制、LoRA 与 Head。固定任务下可表达相同的任务常量，但优化动态改变，需要重新训练验证；该简化尚未实施。

六 实验口径与记录依据

AIDER LoRA 实验设置

项目	当前记录
实验与检查点	two_stage；前 5 轮 dense，后 5 轮 adapter；best 检查点；模型 seed 42
数据规模	训练 461 个视频，共 1,844 条任务记录；测试 115 个视频，共 460 条任务记录
训练预算	batch 8，尾批 4 条；每轮 231 步，共 10 轮、2,310 步
优化设置	AdamW；基础学习率 0.0001；BLIP 文本部分 0.00001；weight decay 0.05
精度与调度	BF16 前向；FP32 可训练参数与 Adam 状态；warmup 116 步，连续余弦调度
损失	FP32 Smooth L1，beta 0.1，样本均值；不包含 MoE 互信息或其他辅助损失
选模口径	第 6 至 10 轮按测试集四任务宏平均 SROCC 严格提升选择 best；并列保留较早轮次

测试集参与了检查点选择，因此该 best 分数包含选模影响。正式比较泛化能力时，应统一基线的数据划分与选模协议，并重复关键模型种子或划分。当前代码归档保存源码与配置，完整运行还依赖原服务器的数据、预训练权重和缓存路径。[S3]

记录依据

[S1] AIDER-LoRA 指标快照。2026 年 10 月 28 日研究者提供原始 metrics，并确认对应两阶段 5+5 的 best。表格保留四位小数；宏平均已按四维算术平均核对。

[S2] AIDER-LoRA 模型源码。/Users/zelu/Desktop/Codes/AIDER-main/AIDER-LoRA/models/ 下的 aider.py、fusion.py、lora.py、film.py、task_private.py；MoE 参数对照为父项目 models/。

[S3] AIDER-LoRA 训练与归档。/Users/zelu/Desktop/Codes/AIDER-main/AIDER-LoRA/ 下的 README.md、config.yaml、COPY_INFO.md、engine/optim.py 与 engine/trainer.py。

[S4] 意图投影数据与训练。/Users/zelu/Desktop/Codes/AIGVQA Task Embedding/ 下的 data/criterion7_intent_v1/manifest.json、work/intent_v1/train_projection.py 与 aigvqa_mapper/criterion_projection.py。

[S5] 意图投影效果。/Users/zelu/Desktop/Codes/AIGVQA Task Embedding/results/criterion7-intent-projection-v1/ 下的 comparison_summary.csv、report.json 与 protocol.json。